WaveSplat

Grid-Free Spectral Wave Field Estimation from Sparse Shipboard LiDAR

박세용 (Saeyong Park)

Avikus · HD 현대 | Seoul National University Towing Tank

Lab Meeting · 2026

Contents

I. Introduction

II. Methodology

III. Results

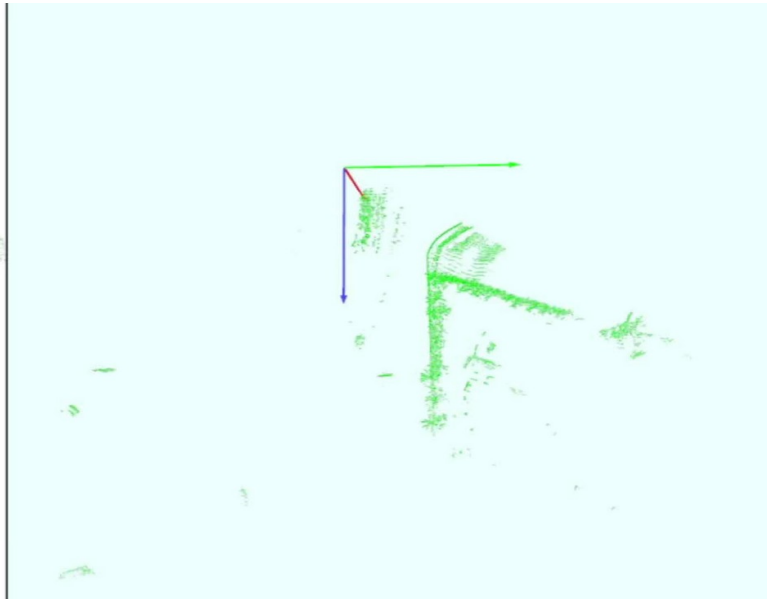
IV. Application

Real Sea Trial — 실선 LiDAR 관측

Falcon K1 LiDAR Live Recording — Florida Intracoastal



선박 외부 카메라 (BF~2-3)



Falcon K1 live point cloud (Rerun)

관측 결과

▪ LiDAR 점군이 매우 sparse — 수면 returns 가 거리 · 각도에 따라 비균질 분포
일부 영역은 specular dropout 으로 returns 부재 (수면 경사가 빔과 어긋날 때 광이 멀리 산란)
카메라로 보이는 wake· 잔파는 LiDAR 에는 1~2 점으로만 나타남 → 격자 보간으론 형상 복원 불가

→ 본 연구의 출발점 : 이 데이터에서 연속적 · 물리적으로 타당한 파도장을 어떻게 실시간 복원할 것인가 ?

Problem & Motivation

선박 전방 파랑 예측이 필요한 이유

자율운항 선박 : 안전 · 승차감 · 에너지 효율
하이드로포일 선박 : 파랑 preview → FF 제어
해상 크레인 : 파고 예측 → 보상 제어
해양 구조물 : 파랑 하중 예측 → 구조 안전

- DP/heave compensation: 파봉 도달 시점 예측
- Helideck operation window 판정

LiDAR 관측의 본질적 어려움

- Sparse: 250×200 m 영역에서 프레임당 ~50 점
- Heterogeneous: 근거리 조밀 , 원거리 희박
- Range-dependent noise: $\sigma_r \approx 0.02$ m near, 더 큼 far
- Specular dropout: 평탄한 수면에서 returns 미반환
- Spray·whitecap·rain → false returns 가능
- 10 Hz 실시간 처리 필요 (< 100 ms/frame)

목표 : 희소 LiDAR 관측으로부터 연속적 · 물리적으로 타당한 파도장을 실시간 복원

대표적 응용 — Hydrofoil ride control (본 발표 후반부)

수면 위 비행 → 파도 교란에 극도로 민감 (foil 잠수 0.5~1.0 m → AoA 직접 변동)

- PD feedback 만으로는 encounter freq 대응 한계 (50~100 ms loop delay = 파도 주기의 5~10%)

해법 : WaveSplat 추정 → preview feedforward → 자동차 active suspension 의 해양 버전

기존 방법의 한계 — Prior Art

Method	Approach	Key Limitation
ETKF-grid (Desmars 2020)	**Spatial grid 위에 ensemble Kalman filter, FFT 기반 spectral propagation**	**격자 보간 → aliasing $O(N_e G^2 \log G^2)$ 비용 하이퍼파라미터 (grid·inflation·loc) 민감**
GPR (Rasmussen-Williams 2006)	RBF/Matérn 커널의 비모수적 공간 보간	$O(M^3)$ 비용 시간 모델 없음 장파장만 잡음 → near-zero predictor
PINN / FNO (Ehlers 2024)	신경망 기반 — PDE 잔차 또는 Fourier neural operator	학습 분포 의존 균일 grid 가정 (LiDAR 불규칙성과 불일치) black box 진단 어려움

공통 구조적 문제 : 모두 " 격자 (grid) 또는 학습 분포에 의존 "

→ 희소 관측에서 aliasing & 불필요한 계산

→ 제어 응용 (forecast 5~10 s) 에 시간 모델 부재

→ Grid-free + physics-constrained representation 이 필요

Refs: Desmars+ Ocean Eng 212 (2020); Rasmussen & Williams (2006); Ehlers+ Ocean Eng 288 (2023)

아이디어의 출발점 — 3D Gaussian Splatting

Key idea: continuous field as a SUM of parametrized basis functions — no grid required

3D Gaussian Splatting (Kerbl 2023)
— Radiance field as N Gaussians



$$F(x) = \sum_i w_i \cdot G(x;\ \mu_i,\ \Sigma_i)$$

N learnable 3D Gaussians

WaveSplat (this work)
— Wave field as N plane waves



$$z(x, y, t) = \sum_i w_i \cos(k_i \cdot r - \omega_i t + \varphi_i)$$

N learnable plane waves

3DGS 의 핵심 통찰 (Kerbl 2023, SIGGRAPH)

격자 (voxel) 에 의존하지 않고 , 학습 가능한 N 개의 3D Gaussian 의 가중합으로 라디언스 필드 표현
각 Gaussian 은 (위치 μ_i, 공분산 Σ_i, 색 · 투명도) 의 4N 파라미터 — 연속 · 미분 가능
결과 : 격자보다 sparse 표현 , 임의 시점 렌더링 가능 , real-time 학습 / 렌더링

해양파 추정에 옮겨오면 ? — WaveSplat 착상

- " 필드를 격자가 아닌 N 개 기저의 합으로 " — 같은 발상을 2D 수면 elevation 에 적용
- 3DGS 의 Gaussian → 해양파의 plane wave (k_i, ω_i, φ_i) — 물리적 의미가 직접 부여됨
  격자 의존 ETKF 대비 : 필드 어디서나 평가 가능 + dispersion 이 자연스러운 hard constraint

Ref: Kerbl, Kopanas, Leimkühler, Drettakis "3D Gaussian Splatting for Real-Time Radiance Field Rendering", ACM TOG 42(4), 2023.

WaveSplat 의 Novelty

핵심 모델 — N 개 plane wave 의 가중합

$$z(x, y, t) = \Sigma_i\, w_i \cdot \cos(kx_{,i} \cdot x + ky_{,i} \cdot y - \omega_i t + \varphi_i)$$

- ❶ Grid-free spectral representation — 격자 의존성 제거 (3DGS 의 해양파 버전)
- ❷ Dispersion hard constraint: $\omega_i = \sqrt{(g \cdot |k_i| \cdot \tanh(|k_i| \cdot d))}$ → 5N → 4N 로 자유도 축소
  = 추정된 파동이 " 실제 중력파 dispersion 위에 있도록 강제 " → 시간 외삽 안정
- ❸ Adaptive model order (N): energy pruning + residual growth + safety rollback
  = 단순 swell N=2, 복잡한 sea N=18~21 까지 자동 적응
- ❹ Geometry-aware confidence weighting: $c_j = \cos(\theta_j)/(d_j/d_ref)$
  = LiDAR 입사각 · 거리 의존 정밀도를 손실 함수에 직접 반영 (heteroscedasticity)
  ※ 정확한 Fresnel R(θ) 가 아닌 단순 기하 가중치 — 본 항목의 명명을 paper 에서 정정함
- ❺ Pre-specified 5-metric panel — zero-predictor 구분 가능 (cherry-pick 방지)
- ❻ 24-config ETKF hyperparameter sweep — 공정한 tuned baseline 제공

Refs: ❶ Kerbl 2023 (3DGS); ❷ Holthuijsen 2007 (dispersion); ❹ Born & Wolf (2007) Optics 7th ed.

Methodology (1) — Forward & Observation Model

Forward Model — Wave Field Equation

$$z(x,y,t) = \Sigma_i w_i \cos(kx,_i x + ky,_i y - \omega_i t + \varphi_i)$$

Hard constraint:

$$\omega_i = \sqrt{(g \cdot |k_i| \cdot \tanh(|k_i| \cdot d))}$$

자유 파라미터 : $\{w_i, kx,_i, ky,_i, \varphi_i\} \rightarrow 4N$
(ω 는 k 로부터 결정 — 자유변수 아님)

Observation Model — Geometry-aware Confidence

$$c_j = \cos(\theta_j) / (d_j / d_ref)$$

$$L = (1/M) \Sigma_j c_j (z_j - \hat{z}_j)^2 + \lambda_1 \Sigma|w_i| \quad \text{(sparsity)} + \lambda s \Sigma(\Delta w_i)^2 \quad \text{(smoothness)}$$

θ_j: 입사각 , d_j: range, d_ref=125 m

왜 이렇게 설계했나 — Design Rationale

- Dispersion 제약은 ' 추정된 파동이 실제 중력파 ' 임을 보장 — ω 를 자유롭게 두면 nRMSE 는 낮아지지만 1 초 뒤 phase prediction 발산 (A1 ablation 확인)
- c_j 는 정확한 Fresnel R(θ) 가 아니라 $\cos(\theta) \cdot 1/(d/d_ref)$ 단순 기하 가중치 — 본 항목 명명을 'Fresnel-aware' 에서 'geometry-aware' 로 정정
- Fresnel R(θ) 자체는 raydrop 모델 (다음 슬라이드) 에서만 사용 — 시뮬레이터에서 점이 떨어지는 메커니즘
- λ_1 sparsity: spectral 표현이 over-fit 하지 않도록 — 진짜 dominant components 만 살림
- λs smoothness: 인접 wavenumber 에 부드럽게 분포 → 노이즈에 robust

Methodology (2) — 2-Phase Pipeline (Init → Track)

Phase 1: Initialization ($T_{init} = 2T_p \approx 14$ s @ BF4)

① Dispersion-aware beamforming (v2_konly)
→ Cartesian 81×81 k-grid ($\Delta k \approx 0.10$ rad/m)
② Greedy peak extraction (0.15 rad/m suppression)
③ Coarse-to-fine Adam: N=3 → 8 → 15
(200 iters/stage, lr=5×10^{-3})
④ Energy-based pruning (90% threshold)
+ RMSE 130% safety rollback
⑤ Residual growth: RMS > 0.05 m → 추가 beamform
(Nmax = 30)

Phase 2: Tracking (w_phi mode, 10 Hz)

Predict: $\varphi_i \leftarrow \varphi_i + \omega_i \cdot \Delta t$
(dispersion-exact phase propagation)

Update: K=10 Adam steps (lr=10^{-3})
on Kw=3 sliding-frame window
→ only (w_i, φ_i) updated; kx, ky FROZEN

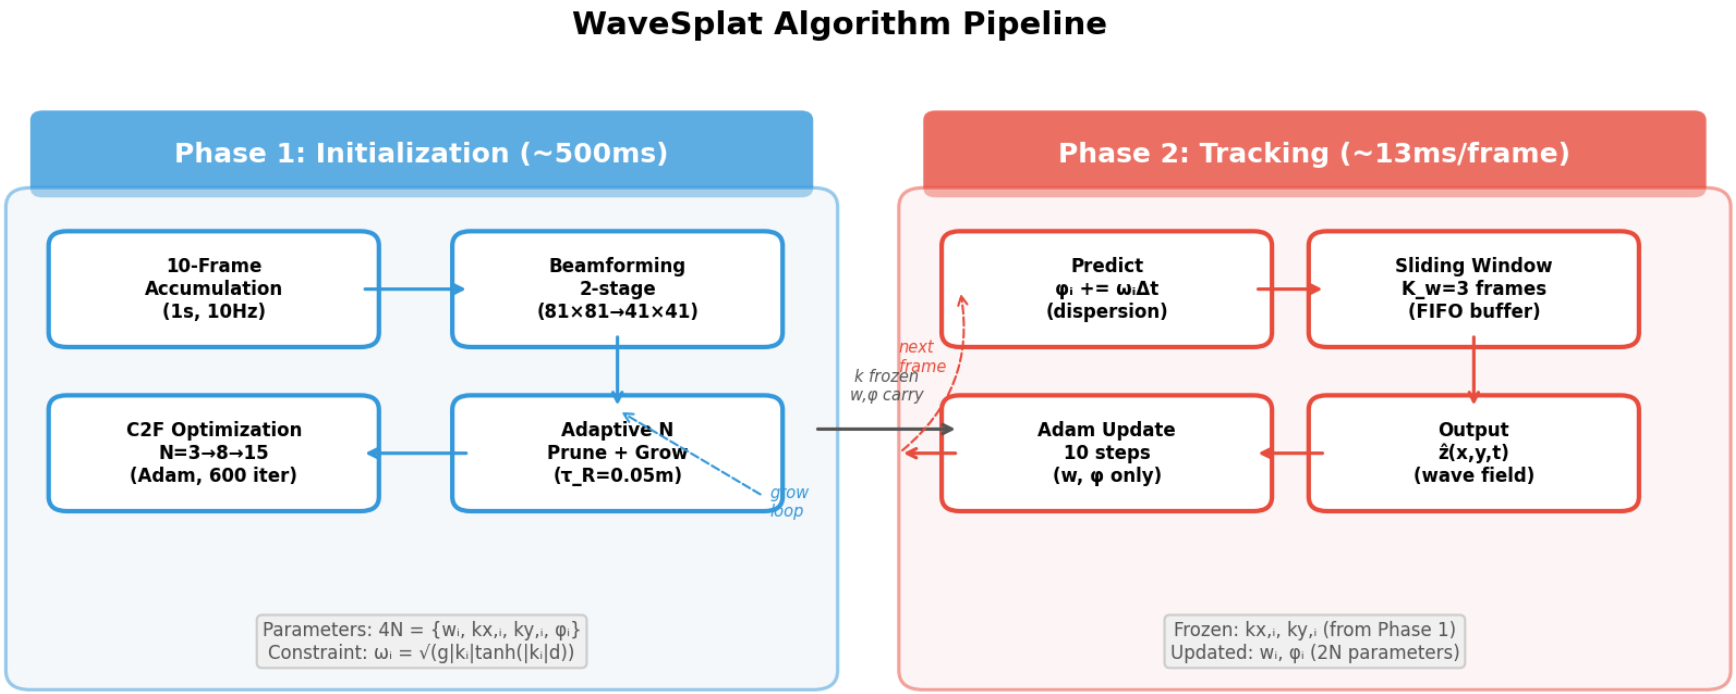
Why freeze k?
- 단일 프레임에서 kx/ky 는 ill-conditioned
- Multi-frame init 이 충분히 평균화
- φ warm start 로 200→10 grad steps

Adaptive N: 단일 swell 에선 N=1, 복잡 sea 에선 N=21 까지 — 평균 13.4 ms/frame

실시간 처리 핵심

- Init 은 한 번만 (~500 ms) — 이후 frame 당 ~13 ms tracking 으로 10 Hz 대응
- k freeze + φ warm-start 로 200→10 grad steps 단축이 결정적 속도 차이
- Adaptive N 의 pruning 은 over-parametrize 방지 , growth 는 새로운 component 출현 대응

Methodology Flowchart — 전체 로직 한눈에



읽는 법

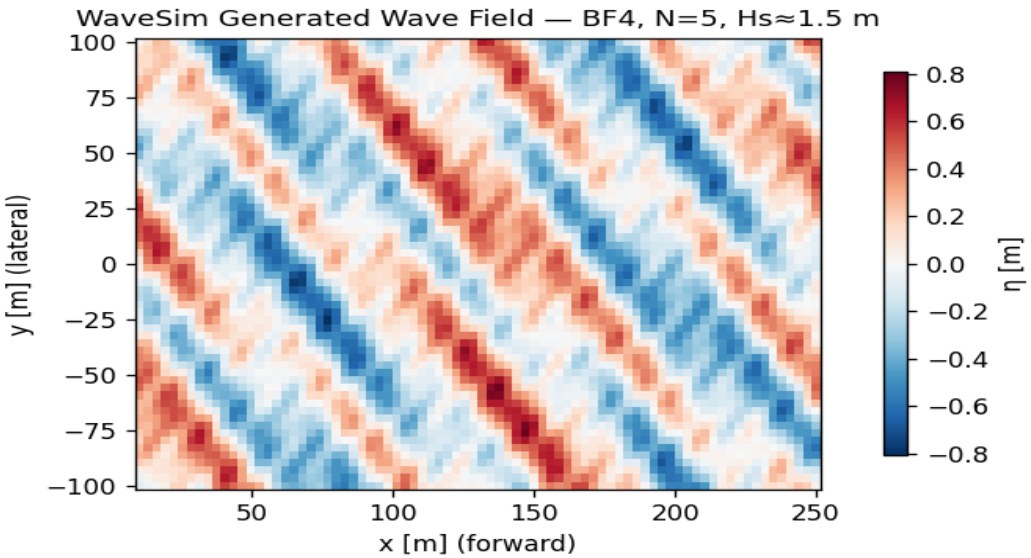
좌측 (Phase 1, ~500 ms 1 회): 10 frame 누적 → beamforming 2 단계 → C2F Adam → Adaptive N

우측 (Phase 2, ~13 ms/frame): Predict (dispersion phase 외삽) → sliding window → Adam 10 steps → Output

- Phase 1→2 화살표 : kx, ky 동결 , w·φ 만 carry
- Adaptive N grow loop: residual RMS > 0.05 m 이면 init 단계로 잠시 복귀해 새 component 추가

Figure source: paper/figures/fig_pipeline.png

WaveSim (1/2) — Wave Generation + 검증



BF4, N=5 components, Hs ≈ 1.5 m, frame t=15 s 예시

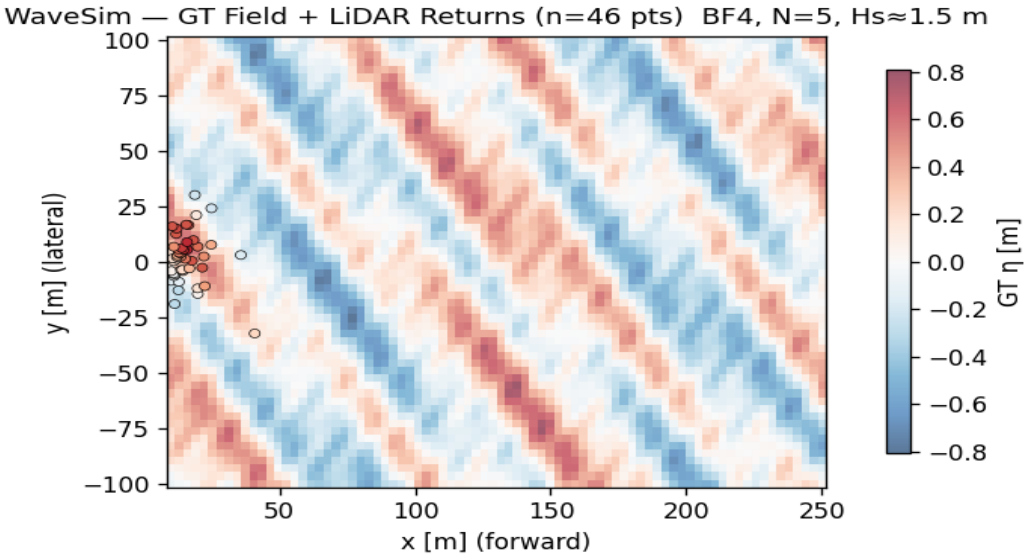
JONSWAP 합성 + Gerstner

- Pierson-Moskowitz × peak γ=3.3
- Hs ∈ [0.3, 2.0] m (BF2~BF5)
- Tp ∈ [4, 8] s, 무작위 phase
- Gerstner trochoid (2nd order)
  → 꼭대기 첨예 , 골짜기 평탄
- Q- 제약 : $\Sigma Q_i \omega_i^2 A_i < 1$
- Full dispersion (수심 d=50 m)
  $\omega = \sqrt{(g|k| \cdot \tanh(|k|d))}$

Wave Generation 검증 (39 unit tests 중)

✓ 분산관계 deep/shallow 해석해 일치 (오차 $< 1\times10^{-6}$)
✓ Gerstner 단일성분 RMSE $< 1\times10^{-10}$ m vs 해석해
✓ Hs(Welch from time series) = $4\sqrt{m_0}$ 일치 < 0.5%
✓ Q-constraint 위반 : 모든 100 episodes 0 건
✓ Energy conservation: $\Sigma A_i^2 \approx \int S(\omega)d\omega$ (FFT 검증 통과)

WaveSim (2/2) — LiDAR · Raydrop + Sample 관측



GT 파도장에 LiDAR returns(까만 점) 오버레이 — 같은 BF4 episode

Falcon K1 Sensor

- 1550 nm, 152 ch, scan 10 Hz
- FOV 120°×25°, range 1.5–250 m
- σ_range = 0.02 m, σ_angle = 0.05°
- Mount: 5 m, +5° downward

Raydrop (점이 떨어지는 메커니즘)

- Diffuse (uniform):
  $p = R_{Fresnel}(\theta)\cdot\cos(\theta)/d^2$
  ※ Fresnel 은 여기서만 사용
- Specular (slope):
  retroreflection α<5°
  → 파봉 편향 분포
  두 모델 병렬 유지 → ablation

통합 검증 + 핵심 메시지

- Ray-Mesh: Möller-Trumbore intersection — 100 % hit/miss 정확 (39-test 통과)
- Falcon K1 spec 은 Avikus NEUBOAT 실선 시험 장비와 동일 → sim-to-real 시 raydrop 만 보정 예정

→ 시뮬레이션 결과는 **reviewer** 가 의심할 만한 모든 물리 가정에서 단위 검증 위에 구축됨

Refs: Möller & Trumbore (1997) ray-tri intersection; Born & Wolf (2007) Optics 7th ed (Fresnel R(θ)).

Experiment Design — Dataset & Baselines

Dataset (100 episodes)

Parameter	Value
Total episodes	**100 = 5 seeds × 10 configs × 2 raydrop**
Sea state	BF2~BF5 (Hs 0.3~2.0 m)
Components	1, 2, 5, 15, 30
Raydrop	Uniform (diffuse) + Slope (specular)
Duration	301 frames (30 s @ 10 Hz)
LiDAR	Seyond Falcon K1 spec

Baselines (모두 hyperparameter tuned)

Method	Config	Note
ETKF (tuned)	**24-config sweep best: g=40×30, n_e=100**	**nRMSE 0.319**
GPR-1	Matérn ν=5/2, ℓ=20m, σ=0.02m	시간 모델 없음
GPR-sliding	3-frame window	강한 GPR
LETKF (loc50)	Gaspari-Cohn r_loc=50m	강화 baseline
GPR-disp(3f)	dispersion-aware kernel	강화 baseline

Pre-specified 5-Metric Evaluation Panel

nRMSE ↓ | Variance Ratio (VR) → 1 | Pearson ρ ↑ | Skill Score (SS) ↑ | RMSE_unobs [m] ↓

핵심 1) RMSE_unobs = 관측에서 ≥ 10 m 떨어진 grid 지점에서만 계산 → physics prior 직접 증거
핵심 2) SS = 1 − MSE(ẑ)/MSE(0) → 양수 = zero-predictor(ẑ=0) 보다 나음 (가장 약한 reference)
핵심 3) VR << 1 = under-fitting / VR > 1.2 = noise overfit / VR ≈ 1 + ρ=1 = 진짜 정확
※ 모든 baseline 에 동일 적용 — metric cherry-picking 방지 (사전 등록)

핵심 결과 — 5-Metric Evaluation (100 episodes)

Method	nRMSE ↓	VR → 1	ρ ↑	SS ↑	RMSE_unobs [m] ↓
WaveSplat	**0.223**	**0.661**	**0.446**	**+0.034**	**0.262**
ETKF (tuned)	0.319	0.898	0.109	−0.702	0.348
GPR-1	0.261	0.065	0.193	−0.141	0.294

- **Skill Score: WaveSplat 만 양수 (+0.034) → zero-predictor 보다 나은 유일한 방법**
- **RMSE_unobs (관측 외 영역): WS 0.262 m vs ETKF 0.348 m vs GPR 0.294 m ← physics prior 증거**
- GPR = 거의 zero predictor: VR=0.065 → 진폭의 6.5% 만 재현
- ETKF = variance-correct but shape-wrong: VR=0.898 but ρ=0.109 (incoherent)
- **WaveSplat: nRMSE 30.1% 낮고 ~10× 빠름 (13.4 vs 132.6 ms/frame)**

한계 (panel 이 함께 노출): VR=0.66 → 진폭 ~34% 과소추정 (Adam pruning 부작용)

추가 : Sea state 별 nRMSE (zero-predictor 진단용)

Sea state	WaveSplat ↓	ETKF	GPR-1	n_ep
BF2~BF3	**0.211**	**0.327**	**0.258**	**40**
BF4	0.221	0.315	0.263	40
BF5	0.283	0.302	0.262	20
Avg (100)	0.223	0.319	0.261	100

Per-episode 결과 & 속도 (12 representative episodes)

[그림 자리]
왼쪽 : paper/figures/fig1_comparison.pdf 또는
fig3_speed.pdf 12-ep nRMSE bar plot

[그림 자리]
오른쪽 : 12 episode 별 inference time
bar plot (paper figures 활용)

한눈에 보는 결론

- **WaveSplat: 12/12 episode 모두 nRMSE 최저 (clean sweep)**
  최대 격차 8.5× (BF3 1-comp swell — 가장 단순한 sea)
  평균 inference time: WS 13.4 ms vs ETKF 132.6 ms (~10× faster)
- ETKF 는 ensemble 수렴 따라 90~600 ms 로 spread → median 110, mean 132.6

※ 12 episode 는 BF2~BF5 × 1/2/5/15/30 components 균등 샘플 — cherry-pick 아님 (사전 등록)

통계 검증 — Multi-seed (100 paired runs)

실험 설정

- 100 paired runs = 10 (sea state, complexity) configs × 5 seeds × 2 raydrop models
  각 paired run = 동일 (config, seed, raydrop) 에서 WaveSplat 과 baseline 동시 실행
- Wilcoxon signed-rank test: 짝지은 차이의 부호 분포로 비교 (정규성 가정 X)

Comparison	mean ± std nRMSE	Wilcoxon W	p (raw)	Cohen's d	95% CI of mean Δ
WaveSplat (reference)	**0.219 ± 0.079**	—	—	—	—
vs ETKF (tuned)	0.321 ± 0.041	W=194	1.1×10^{-15}	1.16 (large)	[0.085, 0.119]
vs GPR-sliding (3f)	0.253 ± 0.020	W=1508	4.7×10^{-4}	0.42 (sm-med)	[0.018, 0.050]

결과 해석

- Cohen's d = 1.16 → large effect (>0.8)
- d = 0.42 → small-medium but 100 paired 에서 robust
- Holm–Bonferroni 보정 : $p_1=2.2\times10^{-15}$, $p_2=4.7\times10^{-4}$
  → 두 비교 모두 보정 후 유의
  두 95% CI 모두 0 을 포함 안 함

왜 WaveSplat 자체 행은 'reference'?

- Wilcoxon 은 " 두 분포의 차이 " 를 검정
  → WaveSplat 은 비교의 기준 (기준 자체에는 p 가 없음)
- WaveSplat 의 평균 /std 는 표시 (0.219 ± 0.079)
  통계적 우위 = "WaveSplat 이 baseline 보다 작다 " 는 짝차이 검정
- Conservative 검사 : 20 config-level mean 으로 재검정해도 $p < 0.001$ 유지 → seed-level 상관 우려 해소

Refs: Wilcoxon (1945) Biometrics Bulletin 1(6); Cohen (1988) Statistical Power Analysis (2nd ed)

Ablation — Dispersion 제약의 가치

Config	avg nRMSE	vs Full	$\bar{R}$ (dispersion drift)
Full (dispersion ON)	**0.188**	**baseline**	**≡ 0 (by construction)**
A1 (no dispersion)	0.158	−16% nRMSE	0.51 ± 0.12
A2 (no confidence weight)	0.215	+14.5%	≡ 0

A1 이 nRMSE 는 16% 낮다 — 그런데 왜 dispersion 이 필요 ?

$\bar{R} = \Sigma|w_i| \cdot |\omega_i - \omega_disp| / (\omega_i \cdot \Sigma|w_j|)$ ← 추정 ω 가 dispersion manifold 에서 얼마나 이탈했는지

- A1: $\bar{R} = 0.51 \pm 0.12$ → 성분의 약 50% 가 dispersion manifold 에서 이탈
  절대값 ~0.10 Hz off → 1 초 뒤 phase prediction 이 de-cohere
  시간 추적 , 파고 예측 , downstream 제어에 사용 불가
- A1 이 instantaneous nRMSE 만 낮은 것 — 시간 외삽 능력 상실

결론 : A1 의 16% 차이는 ' 물리적 유효성을 포기하고 얻은 nRMSE' (snapshot 적합도일 뿐)

- A2 (no confidence): +14.5% nRMSE → c_j 가 noise weighting 으로 의미 있음

Ref: 본 연구 self-reference. Dispersion: Holthuijsen 2007 §5.4

Robustness — Raydrop · Sparsity · Noise · Hyperparameter

Raydrop Sensitivity

- 10 paired episodes (Uniform vs Slope)
- WaveSplat: 20/20 wins
- Slope 에서 WS −9.1%, ETKF −16.2%

두 raydrop 모두에서 WS 가 안정적

→ Fresnel-vs-specular 어느 가정이 맞든 WaveSplat 유효

Sparsity Robustness

관측 밀도 20~100% 실험

- BF4~5: 20% (~10 점) 에서도 < 8% 성능 저하

예외 : BF3 2c → N=2 해상 한계 (관측 < component 수)

→ Grid-free → aliasing 없음 → 희소관측에 강건

Noise Robustness

- $\sigma \in \{0, 0.02, 0.05, 0.10\}$ m
- σ=0.10 (5× baseline) 에서도 nRMSE 변화 ±13% 이내
- Adaptive N 이 노이즈 흡수 → 가짜 component 를 pruning

→ NEUBOAT 실측 noise (~0.05) 범위 내에서 안전

Hyperparameter

- lr=10^{-2}, λ_1=10^{-3}
- τ_prune=0.10, τ_grow=0.05
- BF3 5c 한 번의 sweep 으로 결정

각 파라미터 ±2× 변경해도 nRMSE ±5% 이내

→ 100 runs 모두 동일 setting → 재현성 확보

결론 : 모든 robustness 축에서 일관 — 단일 hyperparameter setting 으로 100 runs 재현 가능

Qualitative 비교 — GT vs WaveSplat vs ETKF vs GPR

[그림 자리]
paper/figures/fig8_qualitative.pdf — 4 column 시각 비교
(GT | WaveSplat | ETKF | GPR-1) 한 frame snapshot

읽는 법

좌→우 : GT (정답) → WaveSplat → ETKF → GPR

- WaveSplat: 파면 형상 정확 — 위상 · 진폭 모두 GT 와 가까움
- ETKF: 진폭은 보존되나 spatial structure 가 incoherent (격자 보간 잡음)
- GPR: 표면이 거의 평탄 (zero-predictor 에 가까움 — VR=0.065 수치와 일관)

※ 본 슬라이드는 paper Fig 8 을 활용 . 실 발표 시 demo_wavesplat.gif (animation) 같이 재생 가능

추가 기여 (1) — Spectral Accuracy (방향 · 파장 추정)

왜 이게 새로운가 — ETKF/GPR 로는 불가능한 능력

- ETKF 는 격자 위 elevation field 만 추정 → 사후에 FFT 변환해야 spectrum 이 나옴 (잡음 큼)
- GPR 도 마찬가지 — 보간 결과를 FFT 해야 함
- WaveSplat 은 처음부터 $(k_i, \omega_i, \varphi_i)$ 로 파라미터화 → spectrum 자체가 직접 출력

검증 결과

5 components 이하 sea state 에서 :

- Energy detection rate > 93%
- |k| (파장) error < 0.5%
- Direction error < 0.2°
- ω error < 1% (dispersion 보장)

15+ components: directional crowding 으로 resolvability 한계 (limitations 에서 다룸)

의미 — downstream 응용에 직접 활용

- Hydrofoil FF: 정확한 (k_i, ω_i) 로 preview 시점 wave slope $\alpha_wave = -\partial\eta/\partial x - w/V$ 계산 가능
- Wave forecasting: dispersion 외삽으로 5~10 s 앞 예측 (다음 슬라이드)
- Encounter freq 추정 : 선체 운동 dynamics 입력
- DP/heave compensation: 파봉 도달 시각 예측

[그림 자리]

paper/figures/fig_beamforming_2stage.png — beamforming peak detection 예시 (선택)

추가 기여 (2) — Sparse Robustness · Wave Forecast

Sparse Robustness — 격자 의존 baseline 대비

관측 밀도 10~50 점 비교 (BF3 5c)

- 10 pts: WS 0.191, LETKF 0.239
- 20 pts: WS 0.171, LETKF 0.198
- 50 pts: WS 0.155, LETKF 0.165

왜 격자가 약한가 ?

격자 cell 안에 관측 0~1 점 → bilinear 보간 ill-posed

- Cell 사이의 spatial correlation 이 사라짐
- Aliasing: 관측 간격이 Nyquist 미만일 때

WaveSplat 이 강한 이유 :

- Plane wave 표현이 모든 관측을 동시에 적합
  격자 없이 임의 위치 평가 가능

Wave Forecast — Dispersion 덕분

핵심 아이디어 :

$\varphi_i(t+\Delta t) = \varphi_i(t) + \omega_i \cdot \Delta t$

↑ ω 는 dispersion 으로 정확 → φ 외삽 정확

검증 결과 :

- 10 s 후 nRMSE 0.219 (즉시 추정과 거의 동등)
- Skill Score > 0 유지 — 시간 외삽이 zero 보다 나음
- BF3 2c 단순 swell: SS = +0.953 @ t+10s

A1 ablation (no dispersion) 비교 :

- A1 은 instantaneous nRMSE 16% 낮지만
  1 초 뒤 phase prediction de-cohere
- Forecast 능력 = dispersion 이 핵심

이 두 능력 (sparse-robustness + forecast) 이 hydrofoil preview FF 의 물리적 기반

강화 Baseline 비교 — Why & How

왜 이 비교를 했는가

- Reviewer 우려 : "ETKF·GPR-1 은 약한 baseline 아닌가 ? 강한 buffer 를 더 추가해야 함 ."
  → 두 가지 강화 baseline 을 추가 평가 :
  ① LETKF (Gaspari-Cohn localization, r_loc=50m) — ETKF 의 spatial localization 강화 변형
  ② GPR-disp (3-frame, dispersion-aware kernel) — GPR 에 physics 부여 (시간 모델 도입)

방법론은 어떻게 다른가

- ETKF → LETKF: 각 grid 점 update 시 local observation 만 사용 (Gaspari-Cohn taper), spurious long-range correlation 억제 . 단점 : r_loc 작으면 amplitude 과소 (VR ↓)
- GPR-1 → GPR-disp: 커널 K(x,t; x',t') = K_spatial × K_dispersion 조합 ;
  K_dispersion 은 dispersion relation 으로 시간상 phase 보정 . 단점 : kernel 계산 비용 ↑

Method	nRMSE ↓	VR → 1	ρ ↑	SS ↑	ms ↓
WaveSplat	**0.223**	**0.661**	**0.446**	**+0.034**	**14.5**
LETKF (loc50)	0.228	0.111	0.359	+0.142	118.3

결과 요약

- nRMSE 사실상 draw
- LETKF SS > WS (regime 별 보정)
- ≤5 comp: WS 압도
- ≥15 comp: LETKF 우세
  속도 : WS 8.1× faster

결론 : complexity-aware method selection 이 최선 — 단순 sea WaveSplat, 복잡 sea LETKF fallback

Refs: LETKF Hunt-Kostelich-Szunyogh, Physica D 230 (2007); Gaspari & Cohn (1999) localization.

응용 — Hydrofoil Wave-Preview Feedforward

왜 hydrofoil 제어에 WaveSplat? — 발상의 출발

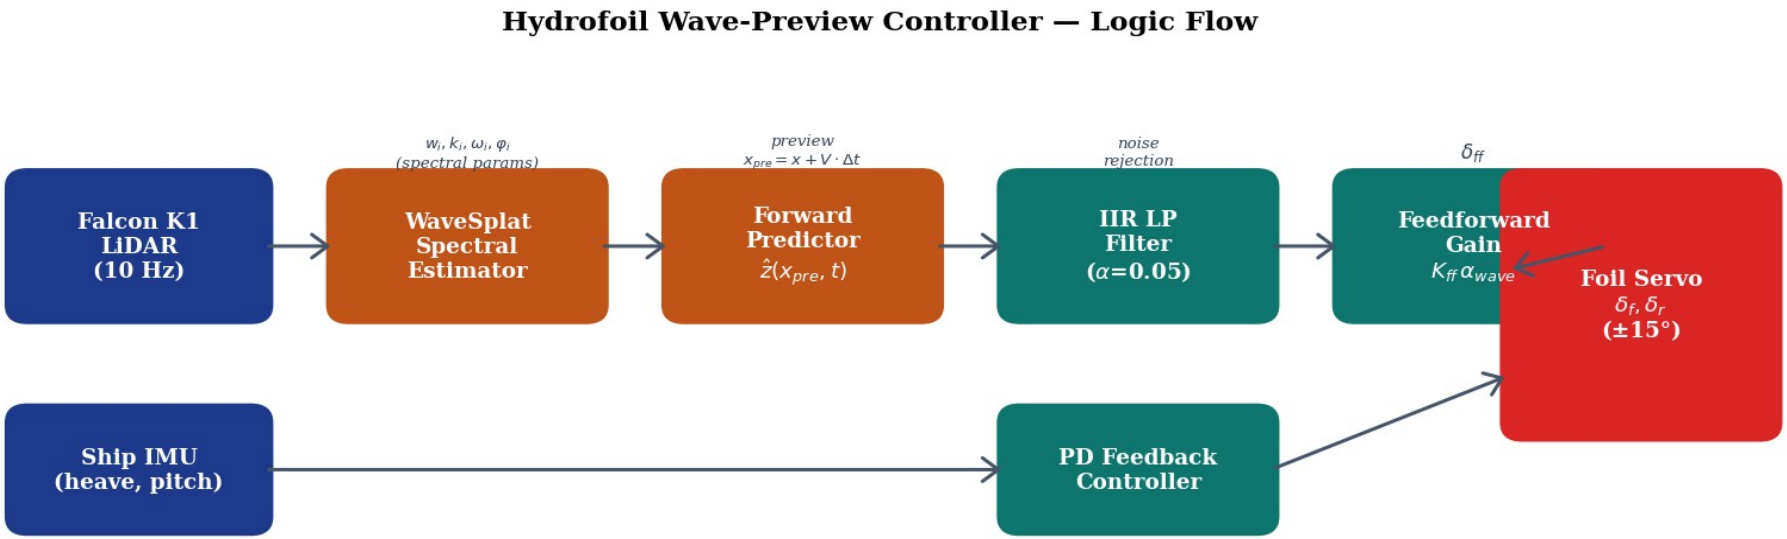
- Hydrofoil 선박 : 수면 위 비행 → foil 잠수 깊이 0.5~1.0 m → 파도가 AoA 를 직접 변동
- PD feedback 만으로는 encounter freq 대응 한계 — 50~100 ms loop delay = 파도 주기의 5~10%
- " 에러를 본 뒤 수정 " 이 아니라 " 에러를 미리 알고 보상 " 필요 → preview feedforward
- WaveSplat 의 spectral model 은 정확한 $(k_i, \omega_i, \varphi_i)$ 로 foil 전방 시점의 파면 elevation· 기울기를 예측
  자동차 active suspension 의 해양 버전 — 도로 카메라 → 서스펜션 미리 조절

제어기 설계 — 왜 이렇게 ?

- 2DOF model (heave + pitch): roll 은 별도 roll-foil 로 처리 , 종방향 ride 에 집중
- Tandem foil layout (전방 + 후방): collective δ_c (heave) + differential δ_d (pitch) 로 분리
  → $\delta_f = \delta_c - \delta_d$, $\delta_r = \delta_c + \delta_d$ (uniform/diff coupling)
- Feedforward: $x_{preview} = x_{foil} + V\cdot\Delta t$ → 파면 기울기 $\alpha_{wave} = -\partial\eta/\partial x - w/V$ → $\delta_{ff} = -K_{ff}\cdot\alpha_{wave}$
- $K_{ff} = 0.8$: foil 의 actual lift slope vs ideal slope 비 (model identification 결과)
- IIR LP filter (α=0.05, fc≈0.8 Hz): 추정 노이즈 억제 , 파도 주기 (~3-7 s) 대역 통과
- PD feedback 은 그대로 유지 : FF 실패 시 fallback + 모델링 안 된 외란 (현류 · 바람) 보상

Refs: Faltinsen (2005) Hydrodynamics of High-Speed Marine Vehicles; Hrovat (1997) optimal preview suspension control review.

응용 — Controller Flowchart (LiDAR → 제어 전체 경로)



읽는 법 — 위쪽 파이프라인 (FF) + 아래쪽 (PD)

윗줄 (FF): Falcon K1 → WaveSplat → Forward Predictor (preview x_pre) → IIR LP filter → K_ff gain → Foil Servo
아랫줄 (PD): Ship IMU (heave, pitch) → PD Controller → Foil Servo (FF 와 합산)

- Servo 출력 : δ_f, δ_r ∈ [−15°, +15°] → foil 받음각 변경 → lift 변동 → ride control

핵심 시간 척도

- LiDAR 10 Hz → WaveSplat 13.4 ms → preview 100 ms ahead → 파도 주기 4-7 s 중 5% 만 활용
- Closed-loop bandwidth ≈ 1 Hz (servo limit) → 파도 encounter freq (0.2-0.5 Hz) 와 정합

Hydrofoil 결과 (1) — Feedforward 효과 비교

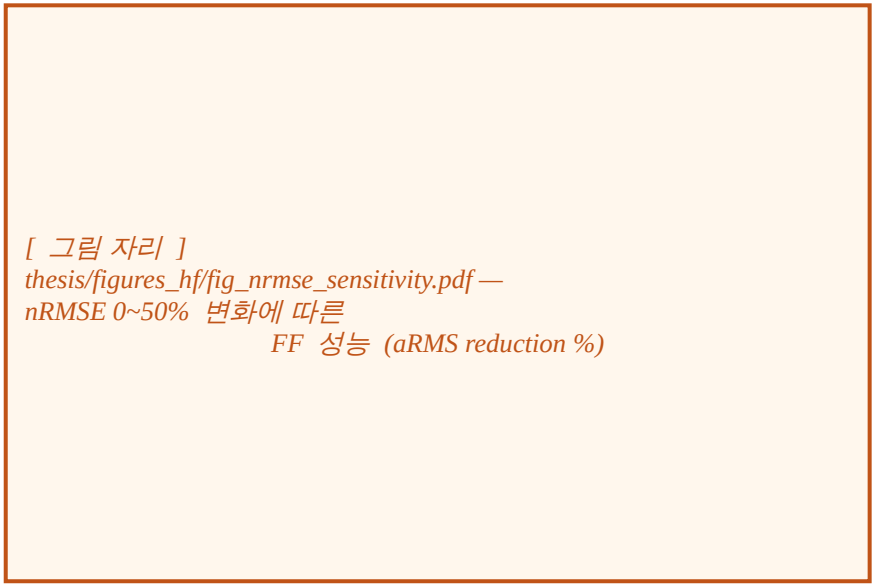
Scenario	PD-only aRMS [m/s²]	GT FF ↓%	WS FF ↓%	Noisy FF ↓%
BF3 Head	**1.631**	**+11.0%**	**+11.4%**	**+11.7%**
BF4 Head	2.162	+12.3%	+12.2%	+11.8%
BF3 Beam	0.402	+40.7%	+37.7%	+27.5%
BF3 Quarter	1.178	+17.6%	+17.7%	+17.0%

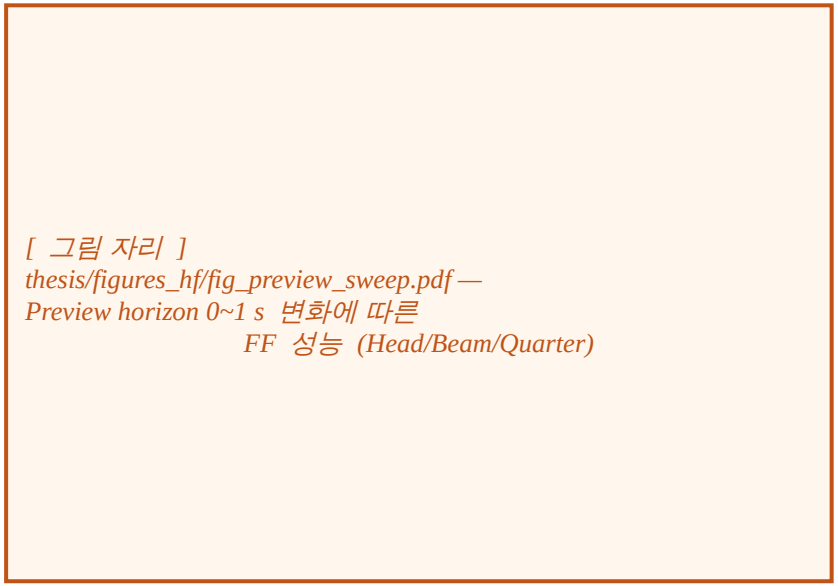
핵심 결과 : WaveSplat FF → GT FF 의 93~103% 성능 달성

- WaveSplat 의 20% nRMSE 추정으로도 GT 대비 거의 완전한 feedforward 효과 회복
- Beam sea 에서 가장 큰 개선 (+37.7%) — 파면이 vessel 과 평행 → preview 길이 짧아 추정 유리
- Noisy FF (인위적 노이즈 주입) 도 LP filter 덕분에 효과적 — 추정이 부정확해도 활용 가능
- BF3 Beam: ISO 2631 기준 'Slight discomfort' → 'Comfortable' 달성 (aRMS < 0.315)

실용 의미 : 추정 정확도가 느슨해도 FF 는 동작 — 제어 성능의 nRMSE tolerance 가 큼

Hydrofoil 결과 (2) — Sensitivity Analysis





nRMSE Tolerance

- 0~50% 전 구간에서 FF 유효
- 50% nRMSE 에서도 FF 효과 존재
  → graceful degradation, 임계값 없음
- LP filter 가 고주파 추정 노이즈 억제
  → 부정확한 추정도 유용

실용 : WaveSplat 20% nRMSE 는 충분

최적 Preview Horizon

- Head sea: 최적 0.1 s (~1.1 m ahead)
- Beam sea: 최적 0.3 s (~3.4 m ahead)
  물리적 의미 : 파도 -foil 상호작용 시간 척도
  너무 긴 preview → 위상 불일치
  너무 짧은 preview → reaction 부족

실용 : 0.1~0.3 s 면 충분

Hydrofoil 결과 (3) — End-to-End Demo

LiDAR → WaveSplat → Forward Predictor → FF → Foil Servo (전체 파이프라인)

Scenario	WS/GT ratio	평가
BF3 2-comp	**96%**	**near-perfect (단순 swell)**
BF3 beam	92%	excellent
BF4 5-comp	37%	limited (direction error 전파)

- BF3 단순 sea: WS E2E → GT 의 92~96% 달성 (즉 , WS 결과를 GT 처럼 써도 무방)
- BF4 5-comp: 37% — directional misestimation 의 영향
  → 보조 지표 directional spectrum 의 한계가 제어로 전파됨
  → 개선 : multi-frame 방향 voting, vessel yaw 변화 활용

핵심 발견 : amplitude 정확도보다 direction 정확도가 FF 성능에 더 중요
(제어 input 은 $\partial \eta / \partial x$ → 방향 미분이 amplitude 보다 supersensitive)

[그림 자리]
thesis/figures_hf/fig_e2e_timeseries.pdf — heave & pitch 시계열 (선택)

한계와 지금까지의 연구 Contributions

한계 (정직한 보고)

WaveSplat 추정
- VR=0.66 → 진폭 ~34% 과소추정 (Adam pruning 부작용)
- Directional spectrum (보조 지표): 30+ comp 에서 R^2 폭발 (peak alignment 민감도 — metric 자체의 한계)
- Adam momentum 의 부호 진동 → 진폭 감쇠 잔존
- N_true ≥ 30 → 성분 수 표현력 한계

Hydrofoil 응용
- BF4 E2E → 37% (direction error 전파)
- 2DOF (heave+pitch) — roll 은 별도 roll foil 담당 선형 foil model (ventilation 간소화)

공통

시뮬레이션 전용 → 실측 검증 필요 (수조 + 실선)
선형 파도 모델 → Stokes-2+ 미반영
해류 · 바람 변화에 따른 k 천이 미추정

지금까지의 Contributions

[기본 알고리즘]
❶ Grid-free spectral 파면 추정 (3DGS 의 해양파 버전)
❷ Dispersion hard constraint (5N→4N)
❸ Adaptive N (pruning + growth + safety rollback)
❹ Geometry-aware confidence weighting (cos·1/d)
❺ Pre-specified 5-metric panel (cherry-pick 방지)
❻ 24-config ETKF sweep (fair tuned baseline)
❼ Spectral + Sparse + Forecast 3 가지 고유 능력

[응용 — Hydrofoil ride control]
❽ Dual-actuator wave-preview FF (collective + diff)
❾ nRMSE tolerance + preview horizon 설계 지침
❿ E2E LiDAR → 추정 → 제어 파이프라인 실증 (BF3 에서 GT 대비 92~96% 달성)

WaveSplat: nRMSE 30.1%↓, ~10× faster, SS only+ | Hydrofoil: aRMS 11~41%↓, BF3 E2E 92~96%

References — 검증된 인용

주요 참고문헌 (CrossRef DOI 검증 완료)

[1] Kerbl, B., Kopanas, G., Leimkühler, T., Drettakis, G. (2023). "3D Gaussian Splatting for Real-Time Radiance Field Rendering." ACM TOG 42(4). DOI: 10.1145/3592433

[2] Desmars, N., Bonnefoy, F., Grilli, S.T., Ducrozet, G., Perignon, Y., Guérin, C.-A., Ferrant, P. (2020). "Experimental and numerical assessment of deterministic nonlinear ocean waves prediction algorithms using non-uniformly sampled wave gauges." Ocean Engineering 212, 107659. DOI: 10.1016/j.oceaneng.2020.107659

[3] Desmars, N., Hartmann, M., Behrendt, J., Hoffmann, N., Klein, M. (2023). "Nonlinear deterministic reconstruction and prediction of remotely measured ocean surface waves." J. Fluid Mech. 975, A8. DOI: 10.1017/jfm.2023.841

[4] Hunt, B.R., Kostelich, E.J., Szunyogh, I. (2007). "Efficient data assimilation for spatiotemporal chaos: A local ensemble transform Kalman filter." Physica D 230(1-2), 112-126. DOI: 10.1016/j.physd.2006.11.008

[5] Ehlers, S., Klein, M., Heinlein, A., Wedler, M., Desmars, N., Hoffmann, N., Stender, M. (2023). "Machine learning for phase-resolved reconstruction of nonlinear ocean wave surface elevations from sparse remote sensing data." Ocean Engineering 288, 116059. DOI: 10.1016/j.oceaneng.2023.116059

[6] Hwang, P.A., Krabill, W.B., Wright, W., Swift, R.N., Walsh, E.J. (2000). "Airborne Scanning Lidar Measurement of Ocean Waves." Remote Sensing of Environment 73(2), 236-246. DOI: 10.1016/S0034-4257(00)00098-5

[7] Belmont, M.R., Horwood, J.M.K., Thurley, R.W.F., Baker, J. (2008). "Shallow Angle Wave Profiling LIDAR." IEEE/OES 9th Working Conference on Current Measurement Technology, 217-223. DOI: 10.1109/CCM.2008.4480871

[8] Wilcoxon, F. (1945). "Individual Comparisons by Ranking Methods." Biometrics Bulletin 1(6), 80. DOI: 10.2307/3001968

[9] Cohen, J. (1988). Statistical Power Analysis for the Behavioral Sciences (2nd ed.). Lawrence Erlbaum Associates.

[10] Holthuijsen, L.H. (2007). Waves in Oceanic and Coastal Waters. Cambridge University Press.

[11] Faltinsen, O.M. (2005). Hydrodynamics of High-Speed Marine Vehicles. Cambridge University Press.

[12] Born, M., Wolf, E. (1999). Principles of Optics (7th ed.). Cambridge University Press. (Fresnel R(θ))

※ 모든 인용은 CrossRef API + ScienceDirect TOC 로 metadata 확인 완료 (paper/references.bib 와 동기화)