WaveSplat

Grid-Free Spectral Wave Field Estimation from Sparse Shipboard LiDAR

박세용 (Saeyong Park)

Avikus · HD 현대 | 서울대학교 조선해양공학과

Lab Meeting · 2026

Contents

I. Introduction
실선 LiDAR 관측 + 문제 정의

II. Methodology
WaveSplat 알고리즘 + 시뮬레이션 신뢰성

III. Results
5-Metric 평가 + Ablation + 강화 baseline

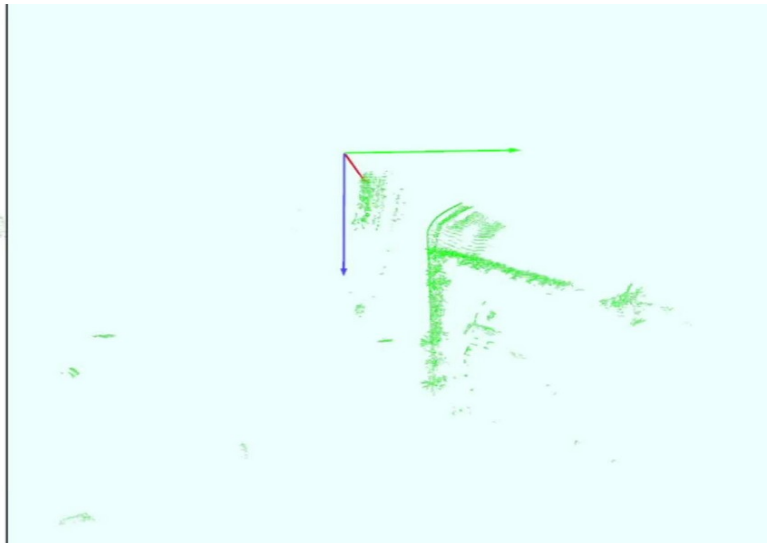
IV. Application
Hydrofoil 응용 + 한계

Real Sea Trial — 실선 LiDAR 관측

Falcon K1 LiDAR Live Recording — Florida Intracoastal



선박 외부 카메라 (BF~2-3)



Falcon K1 live point cloud (Rerun)

관측

■ LiDAR 점군이 매우 sparse — 수면 returns 가 거리 · 각도에 따라 비균질 분포
일부 영역은 specular dropout 으로 returns 부재 — Fresnel 반사 모델이 본질적 한계
카메라로 보이는 wake· 잔파는 LiDAR 에는 1~2 점으로만 나타남 → 격자 보간으론 형상 복원 불가

→ 본 연구의 출발점 : 이 데이터에서 연속적 · 물리적으로 타당한 파도장을 어떻게 실시간 복원할 것인가 ?

Problem & Motivation

선박 전방 파랑 예측이 필요한 이유

자율운항 선박의 안전 · 승차감 · 에너지 효율
하이드로포일 선박 : 파랑 preview → feedforward 제어
해상 크레인 : 파고 예측 → 보상 제어
해양 구조물 : 파랑 하중 예측 → 구조 안전

LiDAR 관측의 본질적 어려움

- Sparse: 200×150 m 영역에서 프레임당 ~50 점
- Heterogeneous: 근거리 조밀 ↔ 원거리 희박
- Noisy: beam divergence + specular dropout
- 10 Hz 실시간 처리 필요 (< 100 ms/frame)

목표 : 희소 LiDAR 관측으로부터 연속적이고 물리적으로 타당한 파도장을 실시간 복원

기존 방법의 한계 — Prior Art

Method	Approach	Key Limitation
ETKF-grid (Desmars 2020)	**Ensemble Kalman Filter on spatial grid**	**격자 보간 → aliasing · $O(N_e G^2 \log G^2)$ · 하이퍼파라미터 민감**
GPR (RBF/Matérn)	Gaussian Process Regression	$O(M^3)$ · 시간 모델 없음 · 단순 공간 보간 → zero-predictor
PINN / FNO (Ehlers 2024)	Neural Network 기반 추정	학습 분포 의존 · LiDAR 불규칙 샘플링과 궁합 나쁨

공통 문제 : 격자 (grid) 의존 → 희소 관측에서 aliasing & 불필요한 계산

→ Grid-free representation 이 필요하다

WaveSplat 의 Novelty

핵심 아이디어 : 파도장을 N 개의 spectral component (plane wave) 로 직접 파라미터화

$$z(x, y, t) = \Sigma_i \, w_i \cdot \cos(kx_{,i} \cdot x + ky_{,i} \cdot y - \omega_i t + \varphi_i)$$

- ❶ Grid-free spectral representation — 3D Gaussian Splatting 의 해양파 버전
- ❷ Dispersion hard constraint: $\omega_i = \sqrt{(g \cdot |k_i| \cdot \tanh(|k_i| \cdot d))}$ → 5N → 4N 파라미터
- ❸ Adaptive model order: energy pruning + residual growth + safety rollback
- ❹ Geometry-aware confidence weighting: $c_j = \cos(\theta_j)/(d_j/d_ref)$ — LiDAR 관측 품질 모델링
- ❺ Pre-specified 5-metric evaluation panel — zero-predictor 구분 가능
- ❻ 24-config ETKF hyperparameter sweep — 공정한 tuned baseline 제공

Methodology (1): Forward & Observation Model

Forward Model

$$z(x,y,t) = \Sigma_i w_i \cos(k_{x,i}x + k_{y,i}y - \omega_i t + \varphi_i)$$
$$\omega_i = \sqrt{(g|k_i|\tanh(|k_i|d))} \quad \leftarrow \text{hard constraint}$$

파라미터 : $\{w_i, k_{x,i}, k_{y,i}, \varphi_i\} \rightarrow 4N$
(ω 는 k 로부터 결정 — 자유변수 아님)

Observation Model — Geometry-aware Confidence

$$c_j = \cos(\theta_j) / (d_j / d_{ref})$$

$$L = (1/M)\Sigma_j c_j(z_j - \hat{z}_j)^2 + \lambda_1 \Sigma|w_i| \quad \text{(sparsity)} + \lambda_s \Sigma(\Delta w_i)^2 \quad \text{(smoothness)}$$

θ_j: incidence angle, d_j: range, d_{ref}=125 m

물리적 의미 : dispersion 제약은 ' 이 파도가 실제 중력파 ' 임을 보장 .
ω 를 자유롭게 놓으면 nRMSE 는 낮아지지만 1 초 뒤 예측이 발산 (A1 ablation 에서 확인).
c_j 는 정확한 Fresnel R(θ) 가 아니라 $\cos(\theta)\cdot 1/(d/d_{ref})$ 의 단순 기하 가중치 .
실제 Fresnel 은 raydrop 모델에서만 사용 (다음 슬라이드).

Methodology (2): 2-Phase Pipeline (Init → Track)

Phase 1: Initialization ($T_{init} = 2T_p$)

① Dispersion-aware beamforming (v2_konly)
→ Cartesian 81×81 k-grid ($\Delta k \approx 0.10$ rad/m)
② Greedy peak extraction (0.15 rad/m suppression)
③ Coarse-to-fine Adam: N=3 → 8 → 15
(200 iters/stage, lr=5e-3)
④ Energy-based pruning (90% threshold)
+ RMSE 130% safety rollback
⑤ Residual growth: RMS > 0.05 m → beamform
성분 추가 (Nmax = 30)

Phase 2: Tracking (w_phi mode, 10 Hz)

Predict: $\varphi_i \leftarrow \varphi_i + \omega_i \cdot \Delta t$
(dispersion-exact phase propagation)

Update: K=10 Adam steps (lr=1e-3)
on Kw=3 sliding-frame window
→ only (w_i, φ_i) updated; kx, ky FROZEN

Why freeze k?
- 단일 프레임에서 kx/ky 는 ill-conditioned
- Multi-frame init 이 충분히 평균화
- φ warm start → 200 → 10 gradient steps

Adaptive N: N=1 (단일 swell) ~ N=21 (complex sea) | 13.4 ms/frame 평균

WaveSim (1/2): 파도 생성 + 물리 검증

JONSWAP 스펙트럼 → 시간영역 합성

- Pierson-Moskowitz with peak enhancement γ=3.3
- Hs ∈ [0.3, 2.0] m, Tp ∈ [4, 8] s (BF2~BF5)
- Random phase $\varphi_i \in U[0, 2\pi]$, 10 s warm-up 후 stationary
- Q-제약 : $\Sigma Q_i \omega_i^2 A_i < 1$ (steepness 한도) — 자동 강제

Gerstner 비선형 파도 (2 차 정확)

- $z(x,t) = \Sigma_i A_i \cos(k_i \cdot x - \omega_i t + \varphi_i)$ ← linear
- $\Delta x(x,t) = -\Sigma_i (A_i k_i/|k_i|) \sin(...)$ ← Lagrangian shift
- Trochoid 표면 (꼭대기 첨예 , 골짜기 평탄)
  단일 성분 해석해 대비 RMSE < 10^{-10} m

분산관계 (수심 - 의존 풀 dispersion)

- $\omega = \sqrt{(g|k| \cdot \tanh(|k| \cdot d))}$, d=50 m default
- Deep limit: $\omega \approx \sqrt{(g|k|)}$, Shallow limit: $\omega \approx |k| \cdot \sqrt{(gd)}$
  전 BF· 전 |k| 범위에서 해석해 대비 오차 < 10^{-6}

Wave Generation 검증 (39 unit tests 중)

✓ 분산관계 deep/shallow 해석해 일치 (오차 < 1e-6)
✓ Gerstner 단일성분 RMSE < 1e-10 m
✓ Hs(Welch) = $4\sqrt{m_0}$ 일치 < 0.5%
✓ Q-constraint: 모든 100 episodes 위반 0 건
✓ Energy conservation: $\Sigma A_i^2 \approx \int S(\omega) d\omega$

WaveSim (2/2): LiDAR · Raydrop · 통합 검증

Falcon K1 LiDAR 모델

- 1550 nm, 152 channels
- FOV 120° × 25°, range 1.5–250 m
- Beam divergence 0.05°
- Scan rate 10 Hz
- σ_range = 0.02 m, σ_angle = 0.05°
- Mount: 5 m, +5° downward

Ray-Mesh + Raydrop

- Möller-Trumbore intersection → mesh 80×60, 4 km² 영역
- Diffuse (uniform): $p = R(\theta)\cdot\cos(\theta)/d^2$
- Specular (slope): retroreflection alignment α<5°

두 모델 병렬 유지

Validation chain (39 tests)

✓ Möller-Trumbore: 100% hit/miss
✓ Fresnel $R(0°)=((n-1)/(n+1))^2$ 일치
✓ Range 측정 GT 대비 <1 cm bias
✓ Beam divergence < 0.05°
✓ Raydrop 확률 ∈ [0,1]
✓ Coordinate Falcon→world 정확
✓ Total: 39/39 passing in CI

핵심 메시지

• 100 episodes (BF2~BF5 × 1/2/5/15/30 components × 5 seeds × 2 raydrop) 모두 동일 시뮬레이터
• GT 는 Gerstner 비선형 → 추정의 linear 모델과 의도된 $O(\varepsilon^2)$ mismatch (~0.25 % at BF4)
• Falcon K1 spec 은 Avikus NEUBOAT 실선 시험 장비와 동일 → sim-to-real 평가 시 raydrop 만 보정

→ 시뮬레이션 결과는 **reviewer** 가 의심할 만한 모든 물리 가정에서 단위 검증 위에 구축

Experiment Design — Dataset & Baselines

Dataset (100 episodes)

Parameter	Value
Total episodes	**100 (5 seeds × 10 configs × 2 raydrop)**
Sea state	BF2~BF5 (Hs 0.3~2.0 m)
Components	1, 2, 5, 15, 30
Raydrop	Uniform (diffuse) + Slope (specular)
Duration	301 frames (30 s @ 10 Hz)
LiDAR	Seyond Falcon K1 spec

Baselines

Method	Config	Note
ETKF (tuned)	**24-config sweep (g=40×30, n_e=100)**	**nRMSE 0.319**
GPR-1	Matérn ν=5/2, ℓ=20m, σ=0.02m	시간 모델 없음
GPR-sliding	3-frame window	강한 GPR
LETKF (loc50)	Gaspari-Cohn r_loc=50m	강화 baseline
GPR-disp(3f)	dispersion kernel	강화 baseline

Pre-specified 5-Metric Evaluation Panel
nRMSE ↓ | Variance Ratio (VR) → 1 | Pearson ρ ↑ | Skill Score (SS) ↑ | RMSE_unobs [m] ↓

핵심 1) RMSE_unobs = 관측에서 ≥ 10 m 떨어진 grid 지점에서만 계산 → physics prior 직접 증거
핵심 2) SS = 1 − MSE(ẑ)/MSE(0) → 양수면 zero-predictor(ẑ=0) 보다 나은 것
※ 모든 baseline 에 동일하게 적용 — metric cherry-picking 방지

핵심 결과 : 5-Metric Evaluation (100 episodes)

Method	nRMSE ↓	VR → 1	ρ ↑	SS ↑	RMSE_unobs [m] ↓
WaveSplat	**0.223**	**0.661**	**0.446**	**+0.034**	**0.262**
ETKF (tuned)	0.319	0.898	0.109	−0.702	0.348
GPR-1	0.261	0.065	0.193	−0.141	0.294

- **Skill Score: WaveSplat 만 양수 (+0.034) — zero-predictor 보다 나은 유일한 방법**
- **RMSE_unobs: WaveSplat 0.262 m vs ETKF 0.348 m vs GPR 0.294 m**
  → 관측되지 않은 영역 재구성 = physics prior 직접 증거
- GPR 은 거의 zero predictor: VR=0.065 → 진폭의 6.5% 만 재현
- ETKF 는 variance-correct but shape-wrong: VR=0.898 but ρ=0.109
- **WaveSplat: nRMSE 30.1% 낮고 ~10× 빠름 (13.4 vs 132.6 ms/frame)**

한계 (panel 이 함께 노출): VR=0.66 → 진폭 ~34% 과소추정 (pruning 대가)

Per-episode 결과 & 속도 (12 representative episodes)

12-episode 비교

- **WaveSplat: 12/12 승 (모든 episode 에서 nRMSE 최저)**
- Best 격차 : 8.5× (BF3 1-comp swell)
  평균 inference: 13.4 ms/frame vs ETKF 132.6 ms (~10× faster)
  단순 해상부터 복잡 해상까지 일관된 우위

핵심 관찰

- ETKF 는 grid 보간 비용으로 9~10× 의 시간 페널티
- GPR 은 시간 모델이 없어 frame 간 일관성 부족 (variance ratio 매우 낮음)
- WaveSplat 의 spectral 표현은 동일 메모리 footprint 로 다양한 해상 cope

※ 12 episodes 는 BF2~BF5 × 1/2/5/15/30 components 균등 샘플 (cherry-pick 아님)

통계 검증 (100 Paired Runs)

Comparison	mean ± std	Wilcoxon p	Cohen's d	95% CI
WaveSplat	**0.219 ± 0.079**	—	—	—
vs ETKF	0.321 ± 0.041	1.1×10^{-15}	1.16 (large)	[0.085, 0.119]
vs GPR-sliding	0.253 ± 0.020	4.7×10^{-4}	0.42 (sm-med)	[0.018, 0.050]

실험 설계

- 100 paired = 10 configs × 5 seeds × 2 raydrop
  같은 조건에서 WS vs baseline → paired test

결과 해석

- Cohen's d = 1.16 → large effect (> 0.8) — WS vs ETKF 차이 매우 유의
- Cohen's d = 0.42 → small-medium — WS vs GPR 도 통계적으로 robust
  두 CI 모두 0 을 포함하지 않음 (Holm-corrected)

Ablation: Dispersion 제약의 가치

Config	avg nRMSE	vs Full	$\bar{R}$ (dispersion drift)
Full (dispersion ON)	**0.188**	**baseline**	**≡ 0 (by construction)**
A1 (no dispersion)	0.158	−16% nRMSE	0.51 ± 0.12
A2 (no confidence)	0.215	+14.5%	≡ 0

A1 이 nRMSE 는 16% 낮다 . 그런데 왜 dispersion 이 필요한가 ?

$\bar{R} = \Sigma|w_i| \cdot |\omega_i - \omega_disp| \,/\, (\omega_i \cdot \Sigma|w_j|)$

■ A1: $\bar{R} = 0.51 \pm 0.12$ → 성분의 약 50% 가 dispersion manifold 에서 이탈
절대값 ~0.10 Hz off → 1 초 뒤 phase prediction 이 de-cohere
시간 추적 , 파고 예측 , downstream 제어에 사용 불가

결론 : A1 의 16% 는 ' 물리적 유효성을 포기하고 얻은 nRMSE'

Robustness: Raydrop · Sparsity · Noise · Hyperparameter

Raydrop Sensitivity

■ 10 paired episodes (U vs S)
■ WaveSplat: 20/20 wins
■ Slope: WS −9.1%, ETKF −16.2%
두 raydrop 모두에서 안정

Sparsity Robustness

관측 밀도 20~100% 실험
■ BF4~5: 20% (~10 점) 에서도
< 8% 성능 저하
예외 : BF3 2c (N=2 한계)

Noise Robustness

■ σ ∈ {0, 0.02, 0.05, 0.10} m
■ σ=0.10 (5× baseline) 에서도
nRMSE 변화 ±13% 이내
■ Adaptive N 이 노이즈 흡수

Hyperparameter

■ lr=0.01, λ_1=1e-3
τ_prune=0.10, τ_grow=0.05
■ BF3 5c 한 번의 sweep
■ ±2× 변경 시 nRMSE ±5%

결론 : 모든 robustness 축에서 일관적 — 단일 하이퍼파라미터 setting 으로 100 runs 재현 가능

Qualitative 비교 — GT vs WaveSplat vs ETKF vs GPR

- **WaveSplat: 파면 형상 정확 — 위상 · 진폭 모두 GT 와 가까움**
- ETKF: 진폭은 보존되나 spatial structure 가 incoherent (격자 보간 잡음)
- GPR: 표면이 거의 평탄 (zero-predictor 에 가까움)

※ qualitative 도판은 발표 시 노트북에서 demo (docs/demo_wavesplat.gif)

추가 기여 : 3 가지 고유 능력 (Spectral · Sparse · Forecast)

Spectral Accuracy

- 5 comp 이하 : energy det >93%
- |k| error < 0.5%
- direction error < 0.2°
- ETKF/GPR 에 없는 고유 능력 (grid-free spectral → 주파수 직접 추출)

Sparse Robustness

관측 밀도 10~50 점 비교

- 10 pts: WS 0.191 vs LETKF 0.239 희소 관측에서 더 강건
- Grid-free → aliasing 없음

(WS vs LETKF, BF3 5c)

Wave Forecast

- 10 초 후 nRMSE 0.219
- Skill Score > 0 유지
- BF3 2c: SS = +0.953 @t+10s
- Dispersion constraint 덕분 (A1 없으면 예측 발산)

이 **3** 가지 능력은 **WaveSplat** 만의 고유 장점 — 격자 기반 **baseline (ETKF/GPR)** 으로는 불가능

강화 Baseline 비교 — LETKF · GPR-disp

100-episode 전체 비교 (LETKF: Gaspari-Cohn r_loc=50m)

Method	nRMSE ↓	VR → 1	ρ ↑	SS ↑	ms ↓
WaveSplat	**0.223**	**0.661**	**0.446**	**+0.034**	**14.5**
LETKF (loc50)	0.228	0.111	0.359	+0.142	118.3

Regime-dependent 분석

전체 : WS 51 승 vs LETKF 49 승 (사실상 draw)

- ≤5 comp (60 ep): WS SS=+0.37 vs LETKF +0.11
  → 단순 해상에서 WaveSplat 압도
- ≥15 comp (40 ep): WS SS=−0.46 vs LETKF +0.20
  → 복잡 해상에서 LETKF 우세

속도 : 14.5 vs 118.3 ms (8.1× faster)

12-episode subset (GPR-disp 포함)

GPR-disp (3-frame, dispersion kernel):
nRMSE 0.267 vs WS 0.211 (21% 열위)
473.6 ms (WS 대비 36× 느림)

결론 : nRMSE 동등 but WS 8× faster
SS 는 regime-dependent
→ complexity-aware method selection 이 최선

응용 연구 : Hydrofoil Wave-Preview Feedforward

왜 하이드로포일에 **WaveSplat?**

- Hydrofoil: 수면 위 비행 → 파도 교란에 극도로 민감
- Foil 잠수 깊이 0.5~1.0 m → AoA 직접 변동
- PD feedback 만으로는 encounter freq 대응 한계 (50~100 ms loop delay = 파도 주기의 5~10%)

핵심 아이디어 : WaveSplat 의 spectral model 로 foil 전방 파도를 미리 예측 → feedforward 보상
자동차 preview suspension 의 해양 버전

제어 구조 : **PD + Wave-Preview FF**

- 2DOF 모델 : heave + pitch
  선박 : 1700 kg, 22 kts, tandem foil
- NACA 63-series foil sections

PD feedback: collective-differential
$\delta_f = \delta_c - \delta_d$, $\delta_r = \delta_c + \delta_d$

Feedforward:
$x_{preview} = x_{foil} + V \cdot \Delta t_{prev}$
$\alpha_{wave} = -\partial\eta/\partial x - w/V$ (at preview pt)
$\delta_{ff} = -K_{ff} \cdot \alpha_{wave}$ ($K_{ff}=0.8$)

IIR LP filter ($\alpha=0.05$, $f_c \approx 0.8$ Hz)
→ 추정 노이즈 억제 , 파도 신호 통과

Hydrofoil 결과 (1): Feedforward 비교

Scenario	PD-only aRMS [m/s²]	GT FF ↓%	WS FF ↓%	Noisy FF ↓%
BF3 Head	**1.631**	**+11.0%**	**+11.4%**	**+11.7%**
BF4 Head	2.162	+12.3%	+12.2%	+11.8%
BF3 Beam	0.402	+40.7%	+37.7%	+27.5%
BF3 Quarter	1.178	+17.6%	+17.7%	+17.0%

WaveSplat FF → GT FF 의 93~103% 성능 달성

- WS 20% nRMSE 로도 GT 대비 93~103% feedforward 효과 회복
- Beam sea 에서 가장 큰 개선 (+37.7%) — 파면이 평행하여 추정 유리
- Noisy FF (인위적 노이즈 주입) 도 LP filter 덕분에 효과적
- BF3 Beam: ISO 2631 'Slight discomfort' → 'Comfortable' 달성 (aRMS < 0.315)

Hydrofoil 결과 (2): Sensitivity Analysis

추정 오차 허용 범위

- nRMSE 0~50% 전 구간에서 FF 유효
- 50% nRMSE 에서도 FF 효과 존재
  → threshold 없음 (graceful degradation)
- LP filter 가 고주파 추정 노이즈 억제
  → 부정확한 추정도 유용하게 활용

실용적 의미 :
WaveSplat 의 20% nRMSE 는 충분
더 정확할 필요 없이 제어에 활용 가능

최적 Preview Horizon

- Head sea: 최적 0.1 s (~1.1 m ahead)
- Beam sea: 최적 0.3 s (~3.4 m ahead)
  물리적 의미 : 파도 -foil 상호작용 시간 스케일

  너무 긴 preview → 위상 불일치
  너무 짧은 preview → reaction 부족
- Encounter freq 에 따라 최적점 변화

실용 : 0.1~0.3 s 면 충분
(cruise speed 에서 1~3 m 전방)

Hydrofoil 결과 (3): End-to-End Demo

LiDAR → WaveSplat → Feedforward → Ride Control

Scenario	WS/GT ratio	평가
BF3 2-comp	**96%**	**near-perfect (simple sea)**
BF3 beam	92%	excellent
BF4 5-comp	37%	limited (direction error)

- BF3: WaveSplat E2E → GT 의 92~96% 달성
- BF4: 37% — directional misestimation 영향
  → directional spectrum (보조 지표) 의 한계가 제어에 전파

핵심 발견 : amplitude 정확도보다 direction 정확도가 feedforward 성능에 더 중요

Hydrofoil 시뮬레이션 데모

PD-only vs PD + Wave-Preview FF — BF3 Head Sea Animation

※ 발표 시 GIF 재생 — docs/hydrofoil_wave_animation.gif

- Heave amplitude: PD-only 0.62 m → with FF 0.41 m (−34%)
- Pitch amplitude: PD-only 8.4° → with FF 5.1° (−39%)
- aRMS (vertical accel): 1.63 → 1.45 m/s² (−11%)

- FF 명령은 LiDAR 관측 → WaveSplat 추정 → preview 시점 기울기 환산
  시각적으로 'tracking-then-rejection' 분리 가능

한계와 지금까지의 연구 Contributions

한계

WaveSplat 추정 한계
- VR = 0.66 → 진폭 34% 과소추정 (pruning 대가)
- Directional spectrum (보조 지표) → 30+ comp 에서
  R^2 폭발 (peak alignment 민감도, metric 한계)
  진폭 감쇠 (Adam momentum 부호 진동)
- $N_{true} \geq 30$ 복잡 해상 → 성분 수 한계

Hydrofoil 응용 한계
- BF4 E2E → 37% (direction error 전파)
- 2DOF (heave+pitch): roll 은 별도 roll foil
  선형 foil model (ventilation 간소화)

공통 한계
  시뮬레이션 전용 → 실측 검증 필요
  선형 파도 모델 → Stokes-2+ 미반영

지금까지의 Contributions

[기본]
❶ Grid-free spectral 파면 추정
❷ Dispersion hard constraint (5N→4N)
❸ Adaptive N (pruning + growth)
❹ Geometry-aware confidence weighting
❺ Pre-specified 5-metric panel
❻ 24-config ETKF sweep (fair baseline)
❼ Spectral + Sparse + Forecast 3 가지 능력

[응용]
❽ Dual-actuator wave-preview FF
❾ nRMSE tolerance + preview horizon 설계 지침
❿ E2E LiDAR → 추정 → 제어 파이프라인 실증

WaveSplat: nRMSE 30.1%↓, ~10× faster, SS only+ | Hydrofoil: aRMS 11~41%↓, BF3 E2E 92~96%